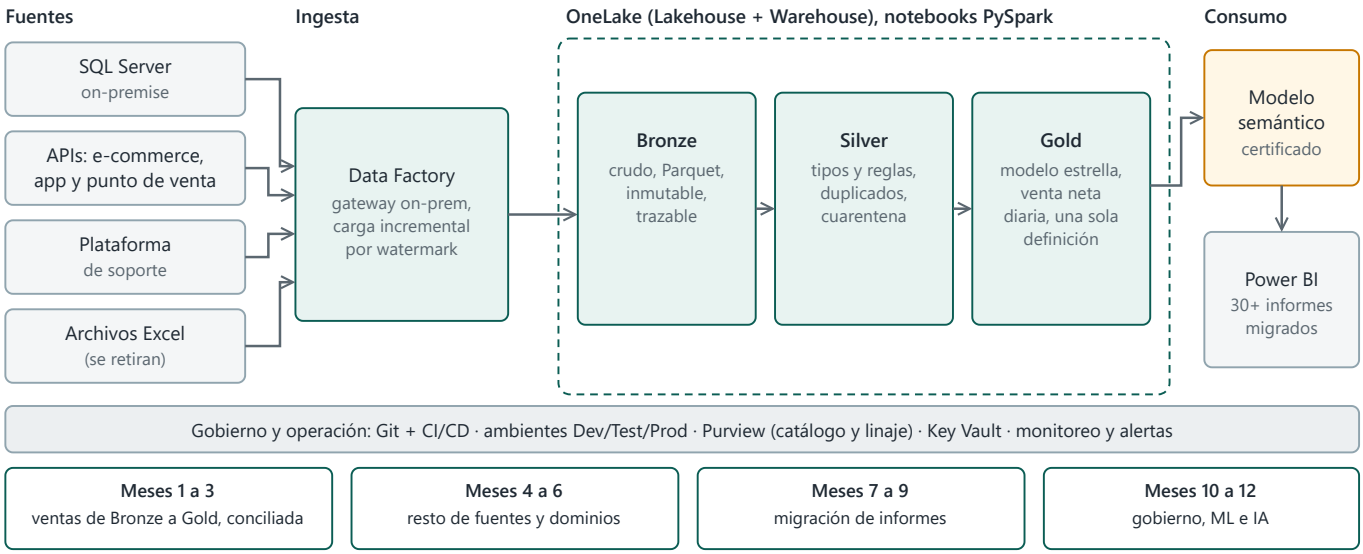
Arquitectura de datos de Andina Market: propuesta a 12 meses

Manuel Alberto Coy Benavides · Prueba técnica, Líder Técnico de Datos, BI y Automatización · Parte 2

1. Arquitectura propuesta



Principio rector: la venta neta se calcula **una sola vez** (capa Gold) y todos los informes la consumen a través de un modelo semántico certificado. Bronze nunca se modifica; Silver aplica reglas de calidad y aparta lo inválido en cuarentena; ningún informe lee Excel ni consulta directo al transaccional.

2. Recomendación: Microsoft Fabric sobre Databricks

	Microsoft Fabric	Databricks
Costo	Una capacidad única cubre ingesta, Spark, almacén y Power BI; se puede pausar y escalar por fase, lo que encaja con un presupuesto aprobado por fases. Ojo: por debajo de F64, quien consume informes necesita licencia Power BI Pro, y pausar una capacidad apaga sus informes (solo se pausa la de desarrollo). Verificar las condiciones vigentes con Microsoft.	Se paga por DBU más la infraestructura cloud aparte y Power BI se licencia por su lado. Es muy eficiente con cargas grandes, pero más difícil de presupuestar. Hay que cotizar ambos con el proveedor; aquí no se inventan cifras.
Riesgo	Producto más joven y de evolución rápida; algunas funciones aún maduran y hay mayor dependencia del ecosistema Microsoft. Se mitiga con formatos abiertos (Delta/Parquet en OneLake) y código Spark portable.	Plataforma más madura para ingeniería y ML. El riesgo es de integración (Power BI, SQL Server on-prem) y de superficie operativa: redes, cuentas, clústeres y gobierno propio.
Capacidad del equipo	Supuesto (el enunciado no describe al equipo): perfil de T-SQL, Power BI y Excel, así que la curva es corta. Direct Lake evita copiar los datos al modelo.	Exige más perfil de ingeniería (Spark, Python, DevOps); la curva es mayor para un equipo de BI.

Decisión: Fabric. La empresa tiene 30+ informes de Power BI, un equipo orientado a SQL y BI y un volumen moderado (decenas de millones de pedidos, no petabytes). **Cambiaría a Databricks** si el volumen crece a decenas de TB, si el ML o el streaming pasan a ser el centro de la estrategia, o si se exige multicloud. Las reglas de calidad de este repositorio están verificadas en Spark local con resultados idénticos a la versión DuckDB; las celdas específicas de Delta y las rutas de cada plataforma no se han probado en Fabric ni en Databricks.

3. Versionar, desplegar y monitorear

- **Git.** Un repositorio por dominio, ramas cortas y pull request obligatorio con revisión (las reglas del punto 3.1 de esta prueba son la lista de chequeo). Se versiona *todo*: notebooks, pipelines, DDL, modelos semánticos y los procedimientos almacenados de hoy, que se migran como código (hoy no tienen versión).
- **Ambientes.** Dev, Test y Prod en espacios de trabajo separados, con datos de prueba enmascarados. La promoción usa pipelines de despliegue de Fabric o GitHub Actions; Prod exige aprobación humana.
- **CI/CD.** En cada PR: lint, pruebas unitarias de las reglas de calidad (este repositorio tiene 90), validación de esquemas y de SQL. Un despliegue fallido se revierte con un `git revert`.
- **Calidad de datos.** Reglas en Silver con cuarentena y conteo por regla. Compuertas: si la cuarentena pasa de un umbral o el volumen del día cae de forma anormal frente a su promedio, la corrida falla y **no se publica Gold**. Conciliación diaria de la venta neta contra la fuente.
- **Alertas.** Monitoring hub y Activator envían a Teams y correo. Los informes ejecutivos salen solo si las verificaciones de las 6:00 pasaron; si no, llega un aviso de "datos en revisión" en lugar de una cifra errónea.
- **Seguridad.** Secretos en Key Vault (nunca en código), permisos por rol y seguridad a nivel de fila en el modelo.

4. Los primeros 90 días y la cifra única de ventas

Días	Entregables
1 a 30	Inventario de los 30+ informes y de los procedimientos almacenados. Definición de «venta neta» firmada por finanzas y comercial (una página: estado entregado, valor bruto menos descuento, fecha del pedido, tratamiento de devoluciones). Repositorio, ambientes y CI en marcha. Ingesta de pedidos, pagos y clientes a Bronze.
31 a 60	Silver con reglas y cuarentena; catálogo de problemas de calidad; Gold de venta neta diaria. **Conciliación contra el SQL Server actual**: diferencia cero o explicada.
61 a 90	Modelo semántico certificado «Ventas» (venta neta, ticket promedio, variación anual). Migración de los informes más usados, empezando por los que dependen de Excel. Alertas y manual de incidentes. Retiro del procedimiento antiguo equivalente.

Cómo se garantiza que todas las áreas usen la misma cifra.

- Una definición escrita y versionada, con un dueño de negocio; cambiarla exige un PR con su aprobación.
- La cifra se calcula una vez: en Gold y en la medida certificada del modelo semántico. Los informes se conectan al modelo, no a Excel ni a consultas propias.
- Los informes que no usan el modelo certificado se marcan «no oficial» hasta migrarlos.
- Conciliación diaria automática (Gold contra fuente) y una alerta si difieren.

Cómo sabremos que funcionó a los 90 días: una cifra conciliada con el sistema actual, al menos 8 informes sobre el modelo certificado, cero credenciales en código y CI en verde en cada cambio.